

Análise Organizacional e Soluções Tecnológicas

Prof. Me. Rafael Gonçalves de
Oliveira Viana

Módulo 2 - Definição do Problema, Coleta e Tratamento de Dados

Unidade 2 – Coleta, Tratamento e Preparação dos Dados

O que será abordado

- A importância dos dados;
- Software versus Biblioteca;
- Análise exploratória inicial.
- Pré processamento dos dados;

A importância dos dados

- Dados são o novo petróleo;
- Dados mal coletados ou mal tratados geram análises ruins;
- Entra lixo, Sai lixo;
- Mineração de dados;
- Exemplo:
 - erros de classificação de dados;
 - dados duplicados e valores ausentes.



Fonte: Binary System Data, www.pixabay.com

Softwares versus Bibliotecas

- Softwares(Orange Lab, Weka, Pentaho, etc.):
 - Pós:
 - fácil operação, sem codificação, ambiente amigável.
 - Contras:
 - limitação de escopo, possível licença de uso.

Softwares versus Bibliotecas

- Bibliotecas(Numpy, Pandas, etc.):
 - Pós:
 - fácil codificação, escalável e robusta.
 - Contras:
 - linguagem de programação, inerente ao programador;

Fonte de dados

- Coletar dados:
 - manual;
 - automático;
 - formato.
- Ferramenta:
 - software;
 - linguagem.

dados.gov.br/dados/conjuntos-dados/2023-a-2025-bolsistas-da-universidade-aberta-do-brasil-uab

 [2023 a 2025] Bolsistas da Universidade Aberta do Brasil (UAB)

[+ Seguir](#) [Avaliar ★](#)

Atualizado  FEDERAL  Aberto

ESCALA DE SATISFAÇÃO / 10

0 - RESPOSTAS ▾

0  Seguindo 33  Downloads

INFO

Os dados disponibilizados contêm informações sobre prestação de contas das atividades de fomento a bolsas de estudo e pesquisas no âmbito dos programas de formação de professores para a educação básica ofertados pela Universidade Aberta do Brasil - UAB.

Organização

 **Fundação Coordenação de Aperfeiçoamento de Pessoal Superior**

A Coordenação de Aperfeiçoamento de Pessoal de Nível Superior (Capes), fundação do Ministério da Educação desempenha papel fundamental na expansão e consolidação da pós-graduação stricto sensu (mestrado e doutorado) em todos os estados da Federação. Em 2007, passou também a atuar na formação de professores da educação superior.

 83 conjuntos de dados  0 reusos

[+ Seguir](#) [Contato ✉](#)

Descrição

Recursos 4

 **BR-CAPES-BOLSISTAS-UAB-2023-2024-07-01**

Ano 2023


 Catalogação: 01/07/2024  Data de atualização do arquivo: 01/07/2024  Downloads: 13

[Acessar o recurso](#) [Preview](#)

Fonte: Mineração de dados, dados.gov.br.

Abrindo *dataset* escolhido no *Orange Lab*

- Abrir *dataset*:
 - *file*;
 - *url*;
 - *SQL*.
- Selecionar dados:
 - automático;
 - manual.



Fonte: Captura de tela do Orange Lab

Abrindo *dataset* escolhido no *Orange Lab*

- Abrir *dataset*:
 - *file*;
 - *url*;
 - *SQL*.
- Selecionar dados:
 - automático;
 - manual.

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

# --- 1. Carregamento e Exploração Inicial dos Dados ---
file_path = 'br-capes-bolsistas-uab-2023-2024-07-01 cópia 2.csv'

try:
    df = pd.read_csv(file_path, delimiter=';', encoding='latin1')
except FileNotFoundError:
    print(f"Erro: O arquivo '{file_path}' não foi encontrado.")
    exit()


print("--- 1. Carregamento dos Dados Concluído ---")
print(f"Total de registros carregados: {len(df)}")
print("\n" + "-"*50 + "\n")

--- 1. Carregamento dos Dados Concluído ---
Total de registros carregados: 116986
-----
```

Fonte: Captura de tela do Colab Google

Identificando os dados

- Visualização:
 - *Data Table*;
- Tipos de dados:
 - categórico;
 - numérico;
 - booleano.



ID	NM_BOLSISTA	CPF_BOLSISTA	NM_ENTIDADE_ENSINO	ENTIDADE_ENSI	ME_REFERENCIA	AN_REFERENC
74542	FERNANDO JOSE GUEDES DA SILVA JUNIOR	***.246.883...	FUNDAÇÃO OSWALDO CRUZ	FIOCRUZ	10	20
74924	FERNANDO JOSE GUEDES DA SILVA JUNIOR	***.246.883...	FUNDAÇÃO OSWALDO CRUZ	FIOCRUZ	11	20
75277	JOVIANA QUINTES AVANCI PINA	***.079.157-**	FUNDAÇÃO OSWALDO CRUZ	FIOCRUZ	11	20
75427	MAURICIO FERNANDO NUNES TEIXEIRA	***.322.960-...	FUNDAÇÃO OSWALDO CRUZ	FIOCRUZ	11	20
75803	JOVIANA QUINTES AVANCI PINA	***.079.157-**	FUNDAÇÃO OSWALDO CRUZ	FIOCRUZ	9	20
75982	SIMONE GRATIVOL MARCHON	***.631.437-**	FUNDAÇÃO OSWALDO CRUZ	FIOCRUZ	11	20
76284	CRISTINA GUEDES VENEU	***.579.847-...	FUNDAÇÃO OSWALDO CRUZ	FIOCRUZ	10	20
76389	FERNANDA MENDES LAGES RIBEIRO	***.013.717-**	FUNDAÇÃO OSWALDO CRUZ	FIOCRUZ	10	20
76533	VANESSA COSTA E SILVA	***.980.437-...	FUNDAÇÃO OSWALDO CRUZ	FIOCRUZ	8	20
76705	ALEXANDRE TEIXEIRA TRINO	***.573.737-**	FUNDAÇÃO OSWALDO CRUZ	FIOCRUZ	11	20
77408	RUBIA WALQUIRIA DE CARVALHO	***.388.006...	FUNDAÇÃO OSWALDO CRUZ	FIOCRUZ	6	20
77714	CAMILLA MAIA FRANCO	***.947.346-...	FUNDAÇÃO OSWALDO CRUZ	FIOCRUZ	8	20
77944	FERNANDO JOSE GUEDES DA SILVA JUNIOR	***.246.883...	FUNDAÇÃO OSWALDO CRUZ	FIOCRUZ	7	20
78054	MONICA LUCIA GOMES DANTAS	***.234.547-...	FUNDAÇÃO OSWALDO CRUZ	FIOCRUZ	8	20
78550	BARBARA ZILLI HAANWINCKEL	***.569.797-**	FUNDAÇÃO OSWALDO CRUZ	FIOCRUZ	11	20
78718	EDUARDO HENRIQUE DE ARRUDA SANTOS	***.174.601-**	FUNDAÇÃO OSWALDO CRUZ	FIOCRUZ	11	20
80349	VANESSA COSTA E SILVA	***.980.437-...	FUNDAÇÃO OSWALDO CRUZ	FIOCRUZ	11	20
80580	MAIRA LOPES MAZOTO	***.354.367-...	FUNDAÇÃO OSWALDO CRUZ	FIOCRUZ	10	20
80740	LETICIA BATISTA DA SILVA	***.913.210-**	FUNDAÇÃO OSWALDO CRUZ	FIOCRUZ	11	20
82202	MAGNA MARIA DA SILVA LEITE	***.731.977-**	FUNDAÇÃO OSWALDO CRUZ	FIOCRUZ	9	20
82383	MAURICIO FERNANDO NUNES TEIXEIRA	***.322.960-...	FUNDAÇÃO OSWALDO CRUZ	FIOCRUZ	10	20
83232	DARLENE CAMARGO GOMES	***.815.407-**	FUNDAÇÃO OSWALDO CRUZ	FIOCRUZ	7	20
83817	EDUARDO HENRIQUE DE ARRUDA SANTOS	***.174.601-**	FUNDAÇÃO OSWALDO CRUZ	FIOCRUZ	8	20
84183	MAGNA MARIA DA SILVA LEITE	***.731.977-**	FUNDAÇÃO OSWALDO CRUZ	FIOCRUZ	8	20
84293	JOVIANA QUINTES AVANCI PINA	***.079.157-**	FUNDAÇÃO OSWALDO CRUZ	FIOCRUZ	7	20
84886	EDUARDO HENRIQUE DE ARRUDA SANTOS	***.174.601-**	FUNDAÇÃO OSWALDO CRUZ	FIOCRUZ	9	20
85135	SIMONE GRATIVOL MARCHON	***.631.437-**	FUNDAÇÃO OSWALDO CRUZ	FIOCRUZ	9	20
85389	SIMONE GONCALVES DE ASSIS	***.077.267-**	FUNDAÇÃO OSWALDO CRUZ	FIOCRUZ	10	20
85772	RUBIA WALQUIRIA DE CARVALHO	***.388.006...	FUNDAÇÃO OSWALDO CRUZ	FIOCRUZ	7	20
85894	VIVIANE DOS SANTOS CHAVES	***.987.767-**	FUNDAÇÃO OSWALDO CRUZ	FIOCRUZ	7	20

Fonte: Captura de tela do Orange Lab

Identificando os dados

- Visualização:
 - *Data Table*;
- Tipos de dados:
 - categórico;
 - numérico;
 - booleano.


```
# 2.2. Visualizar dados
df.head(50)
```

34	FABIANA LUCIANO BUENO PEREIRA	***.265.551-**	UNIVERSIDADE FEDERAL DE MATO GROSSO	UFMT	1	2023	DED	SGB	107	PROFESSOR C
35	RAIMUNDO MANOEL DE JESUS FILHO	***.652.985-**	UNIVERSIDADE FEDERAL DA BAHIA	UFBA	3	2023	DED	SGB	6	TUTOR A
36	RACHEL CAPUCHO COLACIQUE	***.510.288-**	UNIVERSIDADE FEDERAL DO ESTADO DO RIO DE JANEIRO	UNIRIO	2	2023	DED	SGB	1	COORDEN
37	ADRIANA PAULA MARTINS	***.937.386-**	INSTITUTO DE EDUCACAO, CIENCIA E TECNOLOGIA DO...	IFTM	4	2023	DED	SGB	86	PROFESSOR
38	ROMARIO SILVA RIBEIRO	***.933.683-**	INSTITUTO FEDERAL DE EDUCACAO, CIENCIA E TEC...	IFPI	3	2023	DED	SGB	7	TUTOR
39	JULIANA ALMANSA MALAGOLI	***.667.436-**	UNIVERSIDADE FEDERAL DO PARANA	UFPR	3	2023	DED	SGB	86	PROFESSOR
40	KLEBER BERGAMASKI	***.092.049-**	UNIVERSIDADE FEDERAL DE SERGIPE	UFS	5	2023	DED	SGB	86	PROFESSOR
41	RAIMUNDO WILSON PEREIRA DOS SANTOS	***.298.513-**	FUNDAÇÃO O UNIVERSIDADE FEDERAL DO PIAUÁ	FUFPI	5	2023	DED	SGB	1	COORDEN
42	FRANCISCO JOSE GOMES DAMASCENO	***.884.113-**	UNIVERSIDADE ESTADUAL DO CEARÁ	UECE	3	2023	DED	SGB	86	PROFESSOR

Fonte: Captura de tela do Colab Google

Análise exploratória - métricas dos dados

- Visualização:
 - *Feature Statistics;*
- Tipos de estatísticas:
 - média;
 - dispersão;
 - min/max;
 - distribuição.



Fonte: Captura de tela do Orange Lab

Análise exploratória - métricas dos dados

- Visualização:
 - *Feature Statistics;*
- Tipos de estatísticas:
 - média;
 - dispersão;
 - min/max;
 - distribuição.

```
# --- 4. Análises Quantitativas ---
print("--- 4. Análises Quantitativas ---")

print("\n--- 4.1. Estatísticas Descritivas do Valor da Bolsa ---")
print(df['VL_BOLSISTA_PAGAMENTO'].describe().round(2))

print("\n--- 4.2. Contagem de Bolsas por Modalidade ---")
print(df['DS_MODALIDADE_PAGAMENTO'].value_counts())

print("\n--- 4.3. Top 10 Entidades dos Bolsistas ---")
print(df['SG_ENTIDADE_ENSINO'].value_counts().head(10))
print("\n" + "-"*50 + "\n")

--- 4. Análises Quantitativas ---

--- 4.1. Estatísticas Descritivas do Valor da Bolsa ---
count    116986.00
mean      1420.83
std        386.26
min        765.00
25%       1100.00
50%       1100.00
75%       1850.00
max       2100.00
Name: VL_BOLSISTA_PAGAMENTO, dtype: float64

--- 4.2. Contagem de Bolsas por Modalidade ---
DS_MODALIDADE_PAGAMENTO
TUTOR A DISTÂNCIA      40641
```

Fonte: Captura de tela do Colab Google

Análise exploratória - métricas dos dados

- Visualização:
 - *Feature Statistics;*
- Tipos de estatísticas:
 - média;
 - dispersão;
 - min/max;
 - distribuição.

```
# --- 5. Visualização de Dados (Uma análise por vez) ---
print("--- 5. Gerando Visualizações ---")
print("Cada gráfico será exibido em uma janela separada.\n")

# Configura o (parameter) style: str
sns.set_theme(style="whitegrid", palette="viridis")

# ANÁLISE 1: Distribuição dos Valores
plt.figure(figsize=(10, 6))
sns.histplot(df_ufms['VL_BOLSISTA_PAGAMENTO'], kde=True, bins=20)
plt.title('Análise 1: Distribuição dos Valores de Bolsa')
plt.xlabel('Valor da Bolsa (R$)')
plt.ylabel('Frequência')
plt.tight_layout()
plt.show()

# ANÁLISE 2: Boxplot para Outliers
plt.figure(figsize=(10, 6))
sns.boxplot(x=df_ufms['VL_BOLSISTA_PAGAMENTO'])
plt.title('Análise 2: Boxplot dos Valores de Bolsa')
plt.xlabel('Valor da Bolsa (R$)')
plt.tight_layout()
plt.show()
```

Fonte: Captura de tela do Colab Google

Análise exploratória - métricas dos dados


- Visualização:
 - *Feature Statistics;*
- Tipos de estatísticas:
 - média;
 - dispersão;
 - min/max;
 - distribuição.



Fonte: Captura de tela do Colab Google

Análise exploratória - métricas dos dados


- Visualização:
 - *Feature Statistics;*
- Tipos de estatísticas:
 - média;
 - dispersão;
 - min/max;
 - distribuição.



Fonte: Captura de tela do Orange Lab

Pré processamento - Imputação

- Visualização:
 - *impute*;
- Tipos de imputação:
 - média;
 - ocorrências;
 - aleatório;
 - etc.



Fonte: Captura de tela do Orange Lab

Pré processamento - Imputação

- Visualização:
 - *impute*;
- Tipos de imputação:
 - média;
 - ocorrências;
 - aleatório;
 - etc.

```
# --- 3. Imputação de Dados Ausentes ---
print("--- 3. Imputando dados ausentes ---")
if 'VL_BOLSISTA_PAGAMENTO' in df.columns and df['VL_BOLSISTA_PAGAMENTO'].isnull().any():
    mediana_valor = df['VL_BOLSISTA_PAGAMENTO'].median()
    print(f"A mediana dos valores de bolsa é: {mediana_valor:.2f}")
    # Usaremos a mediana para preencher os valores, pois é mais robusta a outliers
    df['VL_BOLSISTA_PAGAMENTO'].fillna(mediana_valor, inplace=True)
    print("Valores ausentes foram preenchidos com a mediana.")
else:
    print("Nenhum valor ausente encontrado em 'VL_BOLSISTA_PAGAMENTO'.")
print("\n" + "-"*50 + "\n")
```

--- 3. Imputando dados ausentes ---
A mediana dos valores de bolsa é: 1100.00
Valores ausentes foram preenchidos com a mediana.

Fonte: Captura de tela do Colab Google

Comparação final

DALIDADE_PAGA	CD_MOEDA	OLSISTA_PAGAMI	VL_BOLSISTA_PAGAMENTO
TUTOR A DI...	R\$	1100	1100
TUTOR A DI...	R\$	1100	1100
TUTOR PRE...	R\$	1100	1100
COORDENA...	R\$	1550	1550
TUTOR A DI...	R\$	1100	1100
COORDENA...	R\$	1500	1500
PROFESSOR...	R\$	1850	1850
TUTOR A DI...	R\$	1100	1100
PROFESSOR...	R\$	?	1420.98
COORDENA...	R\$	?	1420.98
PROFESSOR...	R\$	1300	1300
TUTOR PRE...	R\$	765	765
COORDENA...	R\$	1550	1550
PROFESSOR...	R\$	1850	1850
PROFESSOR...	R\$	?	1420.98
PROFESSOR...	R\$	1850	1850
COORDENA...	R\$	2100	2100
TUTOR A DI...	R\$	1100	1100
TUTOR A DI...	R\$	1100	1100
PROFESSOR...	R\$	?	1420.98
PROFESSOR...	R\$	1300	1300

Fonte: Captura de tela do Orange Lab

Referências

Ferreira, Rafael Gastão Coimbra. et. al. **Preparação e Análise Exploratória de Dados**. Porto Alegre: Sagah, 2021. 1 Recurso Online. Isbn 9786556902890. Disponível na Biblioteca Digital da UFMS

GRUS, Joel. **Data Science do Zero**. Rio de Janeiro: Editora Alta Books, 2021. E-book. p.127-147. ISBN 9788550816463. Disponível na Biblioteca Digital da UFMS.

Licenciamento



Respeitadas as formas de citação formal de autores de acordo com as normas da ABNT NBR 6023 (2018), a não ser que esteja indicado de outra forma, todo material desta apresentação está licenciado sob uma [Licença Creative Commons - Atribuição 4.0 Internacional](https://creativecommons.org/licenses/by/4.0/).

